Açıklanabilir Manipülasyon Risk Skorlama Sistemi

Etiketsiz sosyal medya verisinde, canlı çalışabilen ve kanıt üreten risk scoring pipeline'ı

Ana hikâye

"Supervised classification" değil; label ve test seti olmadığı için doğruluk iddiası kurmadan açıklanabilir risk skoru üretiyoruz.

Label yok | Test seti yok | Canlı inference | Reason-code çıktı

risk_score

risk_band

label

reason_codes

Veri Analizi

Dil, platform, zaman ve tema kırılımları manipülasyon riskini tek boyuta indirgemememiz gerektiğini gösterdi.

risk_map_language_platform.png

Dil × Platform risk haritası

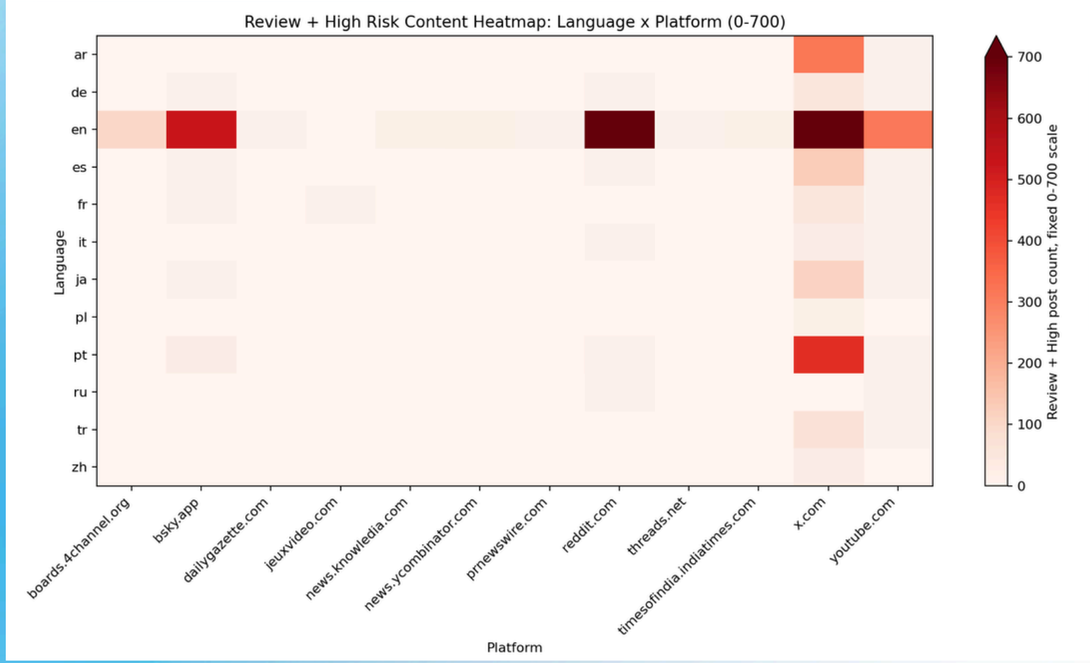

language_manipulative_share.png

Dil kırılımında High paylaşımı

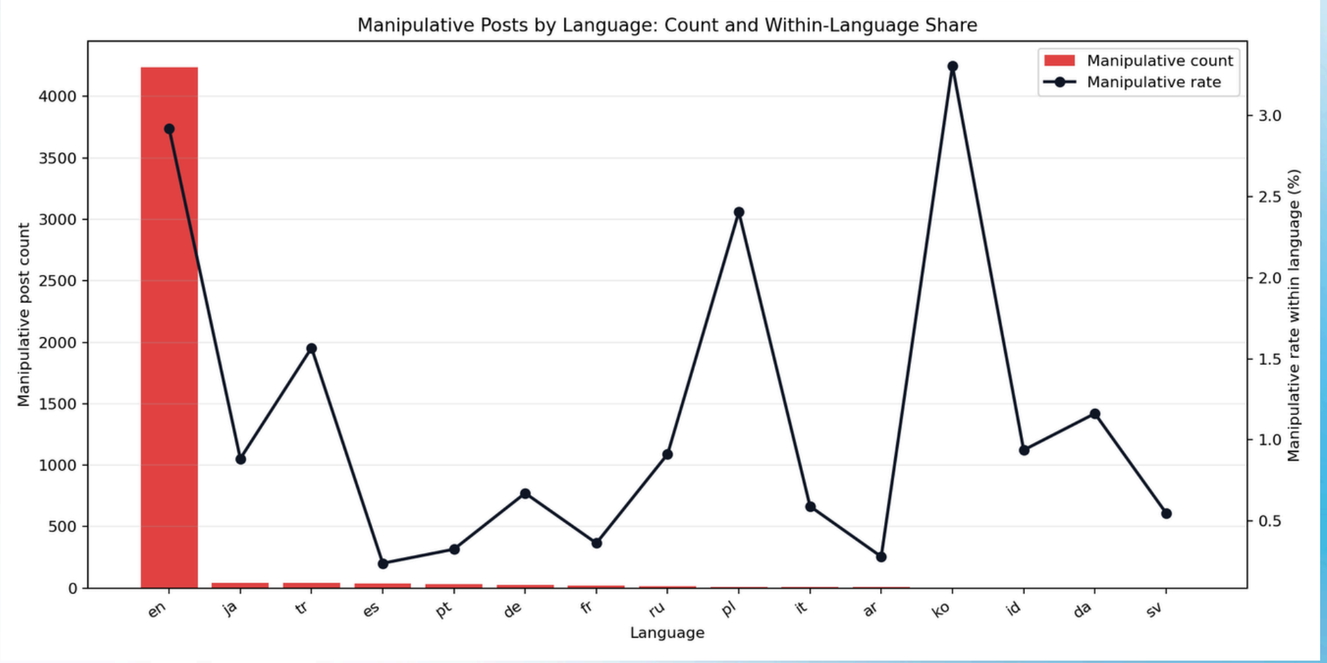

Analiz eksenleri
- Dil / platform
- Zaman penceresi
- Tema / narrative
- Author davranışı

Sonuç: çözüm yalnızca metin sınıflandırması olamaz; platform, dil, author ve coordination sinyalleri birlikte kullanılmalı.

Neden Supervised / LLM Değil?

Problem kurulumuna dürüst yaklaşım: label yoksa accuracy iddiası kurulmaz.

Supervised model	LLM / embedding	Seçilen yaklaşım
Gerçek label yok Etiketli test yok Accuracy iddiası savunulamaz	Dış bağımlılık Latency / maliyet Açıklanabilirlik riski	Deterministic + lokal Reason-code üretir Canlı inference'a hazır

Açıklanabilirlik + canlı çalışma + seçici risk bandı

Feature Engineering

Sinyaller üç ailede toplandı: content, author ve coordination.

Content
CTA, link yoğunluğu, tekrar, sentiment uçluğu, scam pattern, psikolojik tetikleyici

Author
Hacim, burst, tekrar davranışı, tema/dil çeşitliliği

Coordination
Aynı narrative'in farklı author'larca kısa sürede yayılması

feature_importance_proxy.png

Etiketsiz ortamda skor formülüne katkı analizi

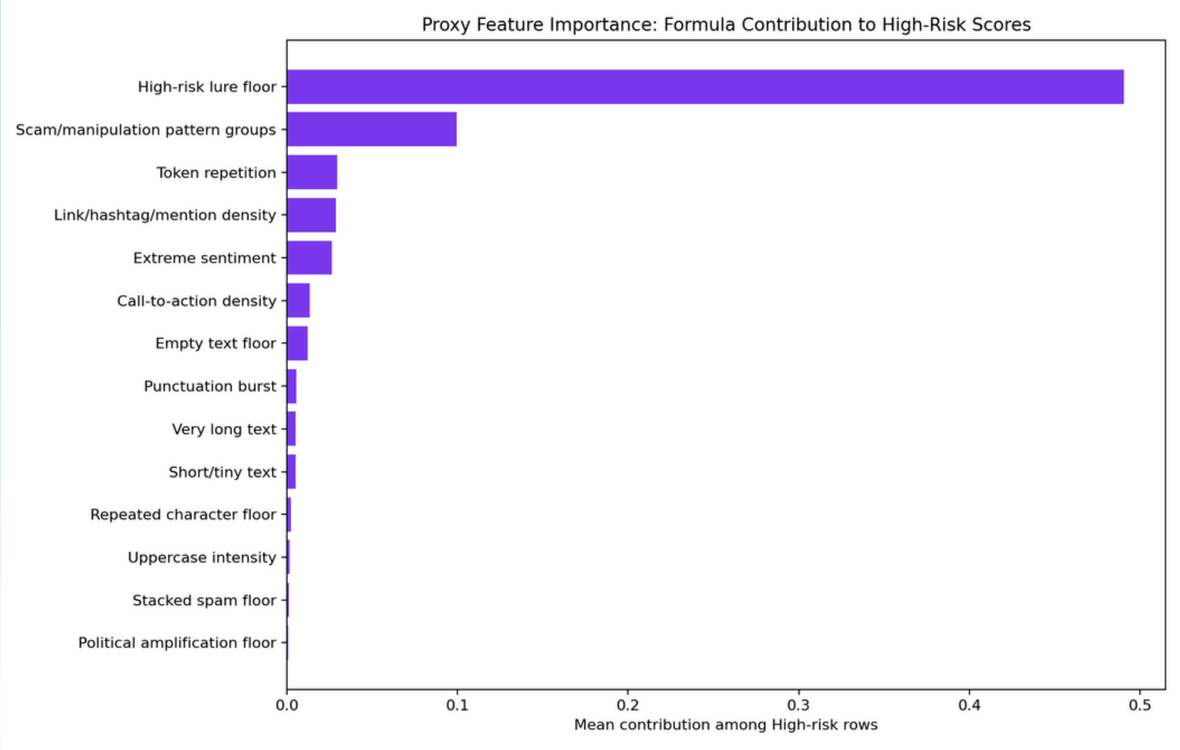

Dikkatli ifade

Bu klasik feature importance değil. Ground truth olmadığı için SHAP / permutation iddiası yok; skor formülüne katkı analizi var.

Skor Mimarisi

Final risk skoru content, author ve coordination bileşenlerinden oluşur.

risk_score = content_risk + author_risk + coordination_risk

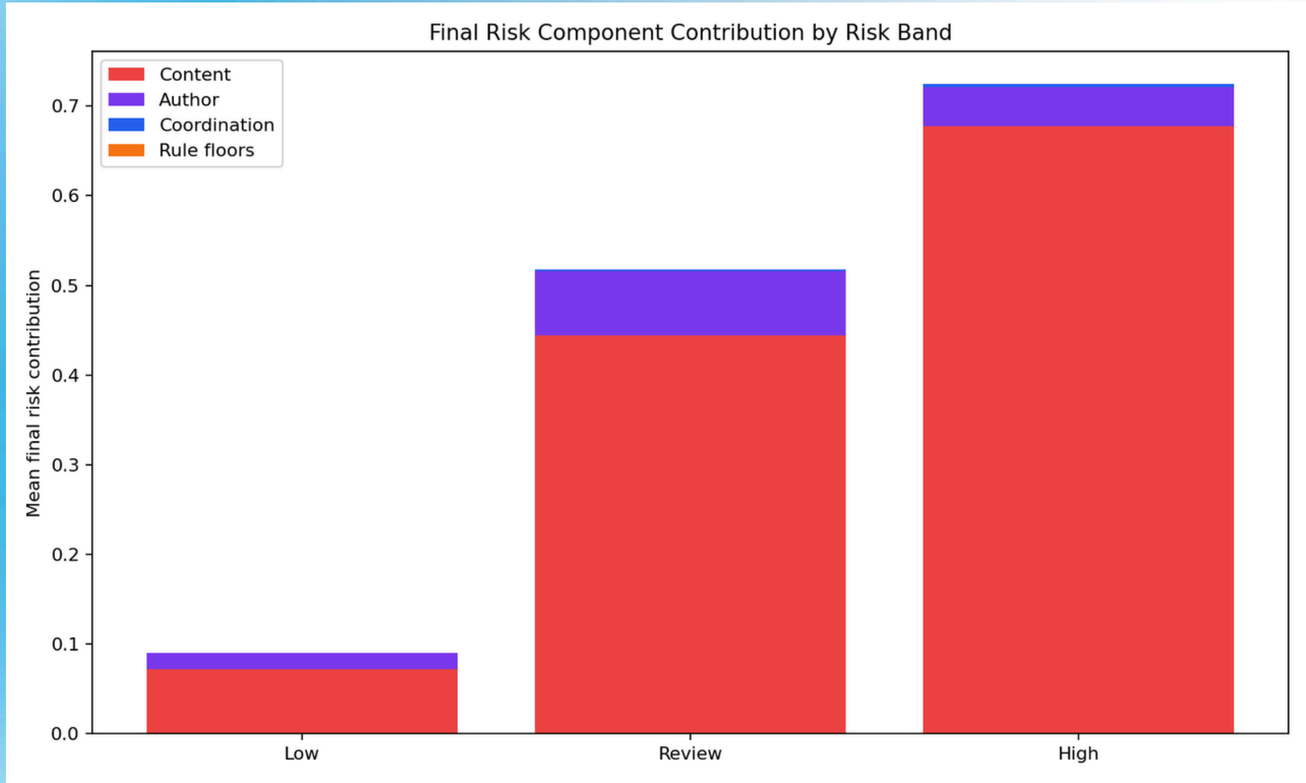

Metadata varsa	Metadata yoksa
Author + coordination kanıtları skoru güçlendirir.	Ağırlıklar yeniden normalize edilir; sistem text-only çalışır.

Kritik tasarım: sadece original_text geldiğinde kırılmayan, metadata geldiğinde daha güçlü kanıt toplayan pipeline.

Açıklanabilirlik

Her kararın arkasında reason code ve psikolojik tetikleyici açıklaması var.

reason_code_breakdown.png

Karar nedenleri

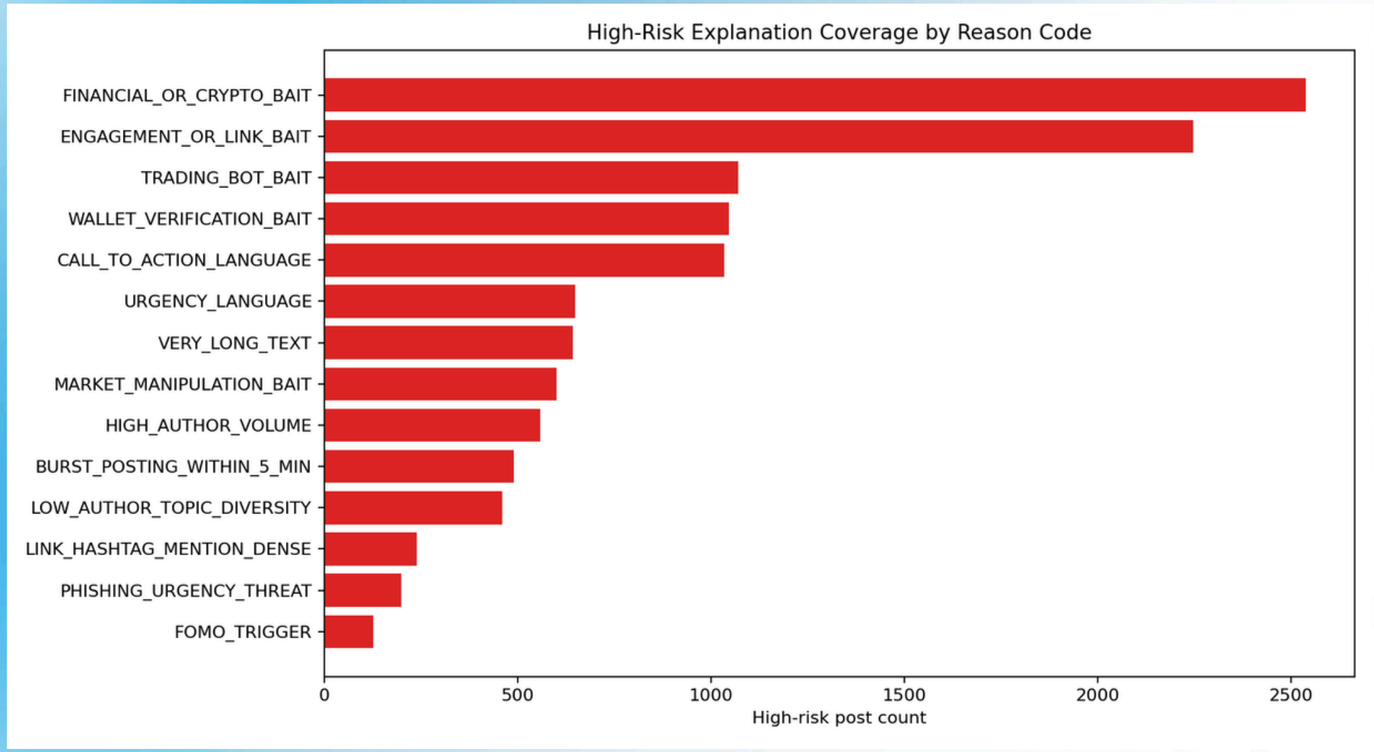

psychological_trigger_breakdown.png

Manipülasyon psikolojisi

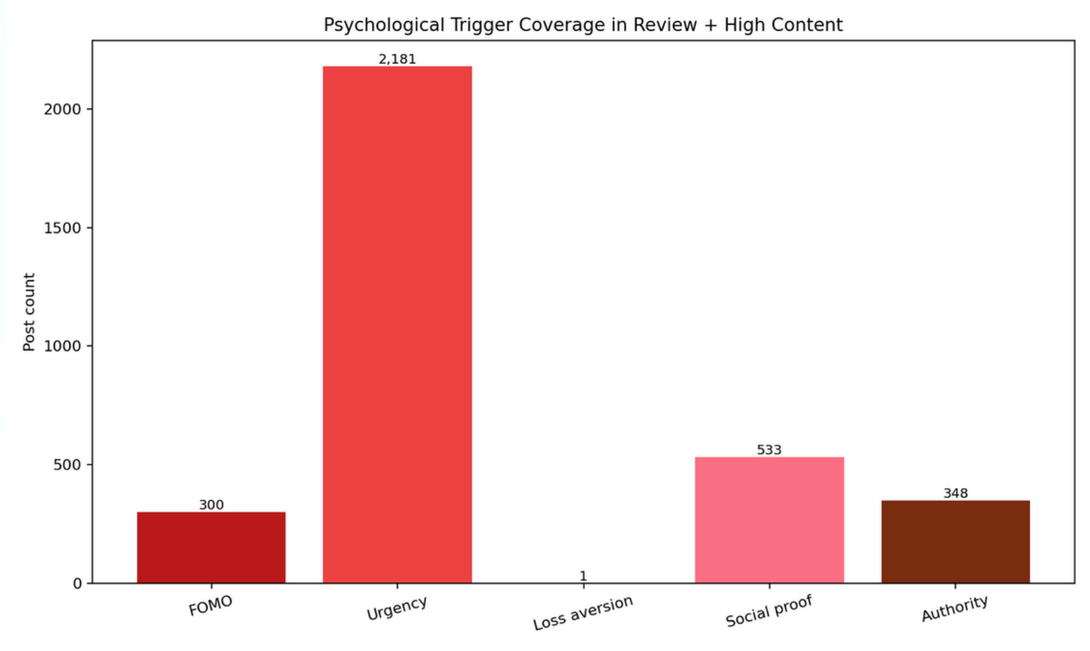

Model kara kutu değil; kararını hangi sinyallerle verdiğini gösteriyor.

Seçicilik ve Risk Bandları

Model her şeyi manipülatif demiyor; belirsiz alanı Review bandında tutuyor.

risk_score_histogram.png + risk_funnel.png

Low	düşük risk	**Review**	incelenmeli
High	Manipulative label	**High** **4.516 satır** **%2,26**	**Review + High** **10.264 satır** **%5,13**

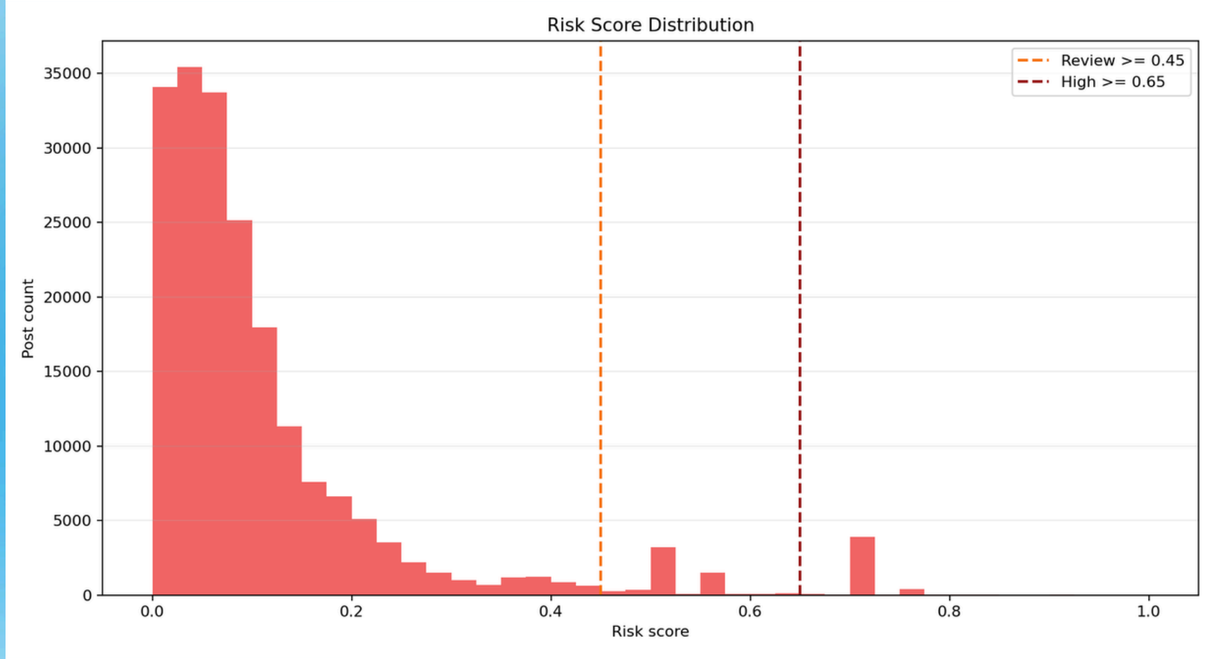

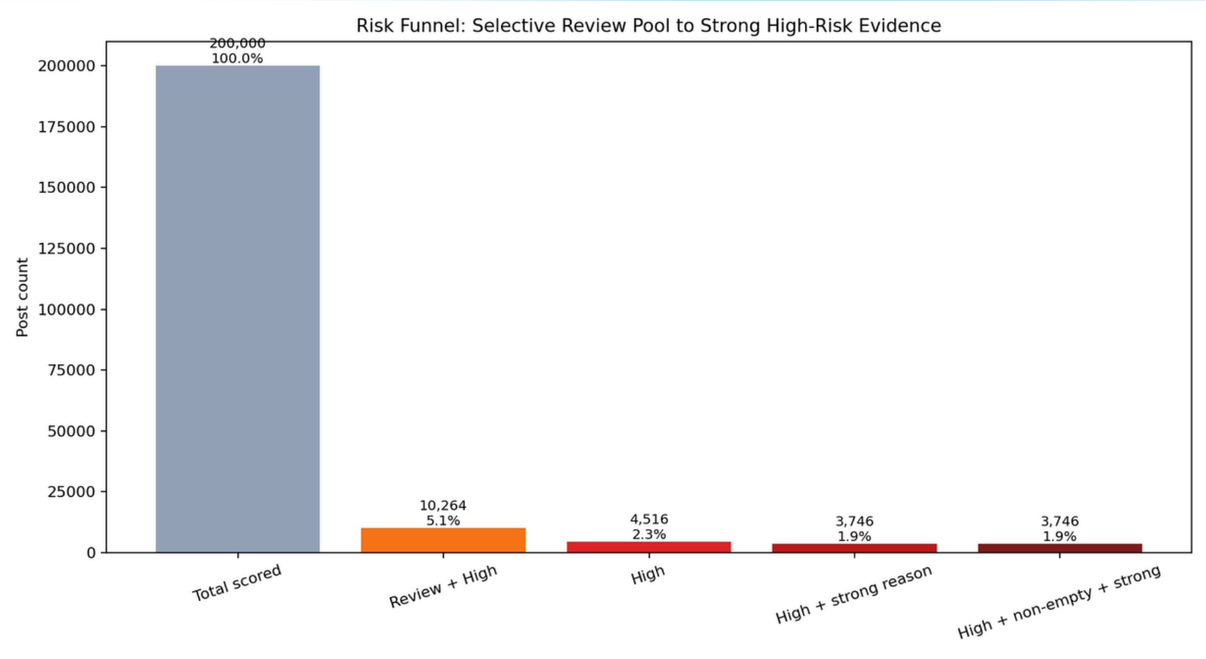

Metadata Kanıtları

Manipülasyon sadece metinden anlaşılmaz; davranış ve yayılım örüntüsü de kanıt üretir.

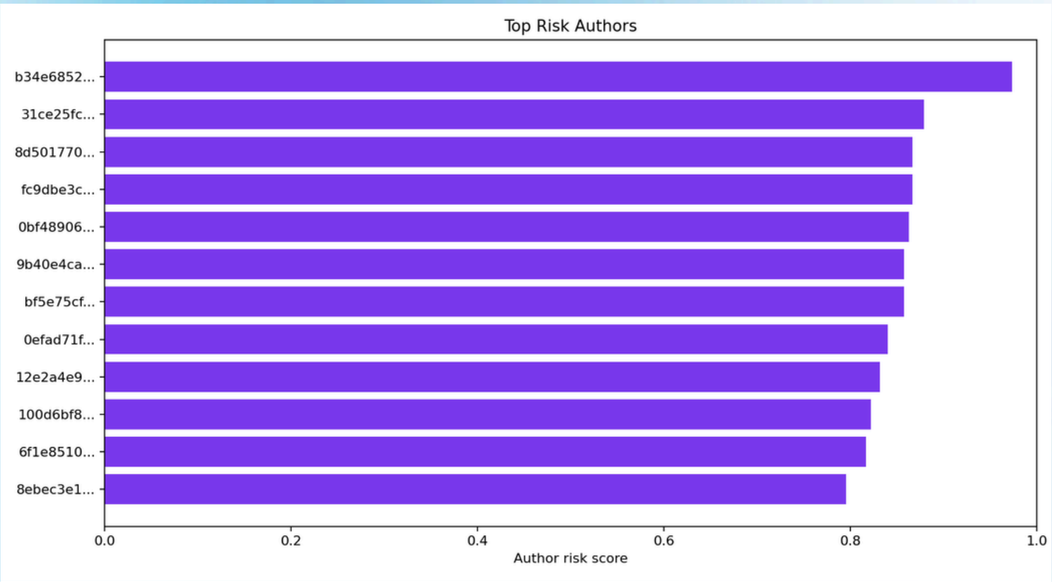

top_risk_authors.png

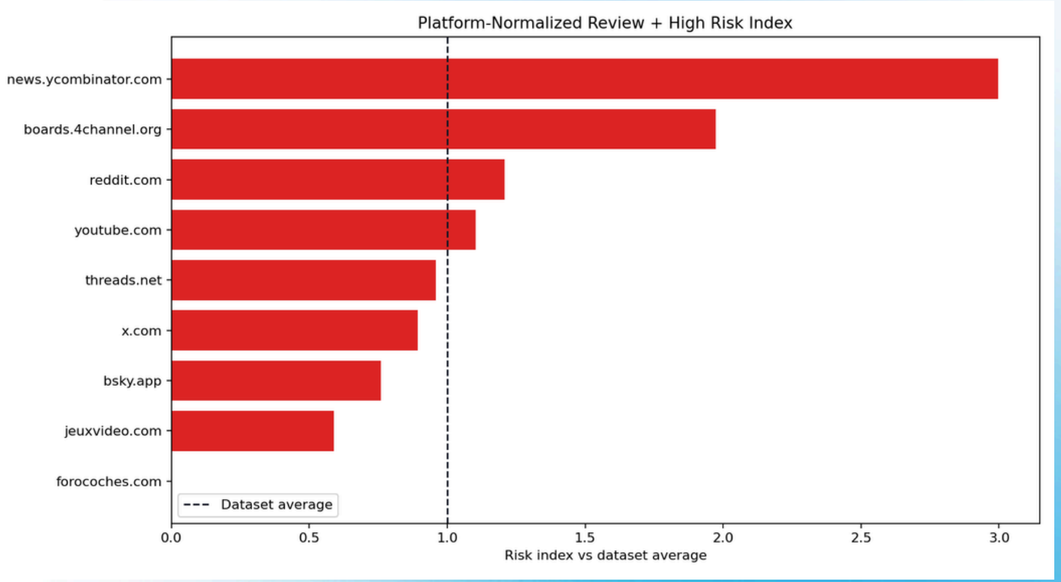

platform_normalized_risk.png

coordination_confidence_bubble.png

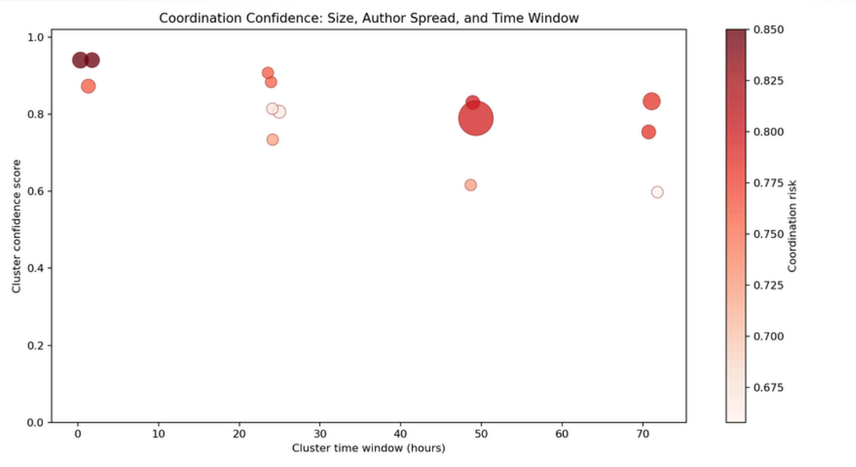

Cluster güveni: author yayılımı × zaman sıkışıklığı × signature zenginliği

Dikkatli ifade: Bu kesin bot tespiti değil; author/coordination risk göstergesi.

Canlı Jüri Testi

Tek metin veya 100+ satırlı CSV için satır bazlı tahmin ve batch summary üretilebilir.

live_inference_benchmark.png

Notebook: Jury CSV Batch Inference

jüri CSV dosyası → pipeline → predictions + summary + grafikler

jury_predictions.csv

summary.md

risk_band_distribution.png

risk_score_histogram.png

reason_code_breakdown.png

psychological_trigger_breakdown.png

Canlı demo mesajı

“Jürinin verdiği dosyada yalnızca original_text olsa bile sistem kırılmadan risk_score, risk_band, label ve reason_codes üretiyor.”

Sonuç ve Sınırlamalar

Etiketli başarı iddiası yerine açıklanabilir, seçici, canlı çalışabilen risk pipeline'ı.

Ne sunduk?	Sınırlamalar	Gerçek dünya ilk adım
Açıklanabilir risk scoring Seçici band yapısı Reason-code kanıtı Canlı inference readiness	İroni ve bağlam Görsel içerik Linkin gerçek içeriği Yeni jargonlar	İnsan etiketli validasyon seti Threshold calibration Baseline karşılaştırması Drift monitoring

case_studies.md + marketing_scorecard.md

"Bu proje, etiketsiz sosyal medya verisinde manipülasyonu kesin hükümle değil, açıklanabilir risk ve kanıt düzeyiyle ele alan canlı çalışabilir bir inference pipeline'dır."

Kaynakça

Spam İstatistikleri ve Bot Türleri
https://www.orbitmedia.com/blog/spam-statistics/
https://www.redsecuretech.co.uk/blog/post/messaging-spam-in-2026-ai-bots-and-auto-join-threats/841
https://www.scworld.com/perspective/how-phishing-changed-in-2025-and-what-to-expect-in-2026-and-beyond
https://securelist.com/new-phishing-and-scam-trends-in-2025/117217/
https://www.splunk.com/en_us/blog/learn/bots-types.html
Kripto, Oltalama ve Bölgesel (Türkiye) Dolandırıcılık Vektörleri
https://www.akamai.com/blog/security-research/crypto-giveaway-scams-are-still-successful
https://www.binance.com/en/square/post/16870081632497
https://www.cnet.com/news/privacy/beware-verification-scams-on-instagram-facebook-and-twitter-red-flags-going-off/
https://www.darkreading.com/cyberattacks-data-breaches/turkish-group-using-phishing-emails-to-hijack-popular-instagram-profiles
https://bidb.kastamonu.edu.tr/index.php/component/content/article/oltalama-phishing-saldirilari?catid=18&Itemid=101
https://sublime.security/blog/talking-year-end-credential-phishing-scams-over-turkey/
https://www.sikayetvar.com/instagram-cekilis-dolandiriciligi/cekilis-kazandiniz?page=8
https://serkansayoglu.com/2025te-turkiyede-sik-gorulen-dolandiricilik-turleri/
Psikolojik Tetikleyiciler ve AI Manipülasyonları
https://amatas.com/blog/the-psychology-behind-phishing-attacks-and-how-to-train-against-it/
https://www.upskillist.com/blog/psychological-triggers-social-media-interaction/
https://www.arfadia.com/glossary/EN/fomo-fear-of-missing-out-marketing
https://pmc.ncbi.nlm.nih.gov/articles/PMC6629481/
https://cdn.openai.com/threat-intelligence-reports/disrupting-malicious-uses-of-our-models-february-2025-update.pdf
https://www.reddit.com/r/Scams/comments/wkzm1w/i_fell_for_the_pig_butchering_romance_scam/
Platform Politikaları ve Küresel Tehdit İstihbaratı
https://www.tandfonline.com/doi/full/10.1080/1369118X.2025.2590561
https://arxiv.org/html/2408.01257v2
https://www.trellix.com/advanced-research-center/threat-reports/april-2025/
https://www.socialmediatoday.com/news/meta-platform-manipulation-trends-adversarial-threat/701230/
https://bizenglish.adaderana.lk/tiktok-releases-q4-2025-community-guidelines-enforcement-report/
Savunma Yöntemleri, Bot Tespiti ve Gizlilik
https://ai.stonybrook.edu/about-us/News/study-suggests-new-strategy-detect-social-bots
https://www.propastop.org/en/2025/03/25/the-silent-infiltrators-spot-the-bot-and-see-how-they-shape-social-media/
https://www.vectra.ai/topics/ai-scams
https://hide.me/en/blog/social-media-privacy-settings-analysis/
https://www.brside.com/academy/ultimate-instagram-security-guide-protect-your-data
https://www.crystalmediaco.com/using-hidden-words-to-avoid-instagram-spam-comments/
https://github.com/tkorkunckaya/Turkish-Stopwords